VIETNAM NATIONAL UNIVERSITY HO CHI MINH CITY
HO CHI MINH CITY UNIVERSITY OF TECHNOLOGY
FACULTY OF COMPUTER SCIENCE AND ENGINEERING

BIG DATA (CO3138)

LAB 02

SPARK STREAMING

Advisor(s): ĐOÀN NGÔ ĐỨC PHƯƠNG
Student(s): Huỳnh Kim Quý - 2312894
Nguyễn Đức Trung Kiên - 2311734

HO CHI MINH CITY, APRIL 2026

1 Tổng quát

Lab02 hướng dẫn chúng ta cách hiện thực một data streamming. Bằng cách đẩy data vào kafka theo từng batch và các consumer lấy data theo từng batch để xử lí thông tin và xuất kết quả trên màn hình console.
Bài tập này rất quan trọng và có tính ứng dụng cao trong thời đại công nghệ dữ liệu lớn, khi mà dữ liệu được tạo ra liên tục và ứng dụng xử lí theo real-time mang lại nhiều lợi ích cho chủ sở hữu.

2 Kiến trúc

Bài lab sử dụng hai spark để mô phỏng quá trình streamming.

- Spark 1 - Producers dùng để mô phỏng đưa data vào cluster Kafka ở lab01 theo từng đợt, mỗi lần 100 data bao gồm movies, tags và ratings vào đúng từng topic ở kafka

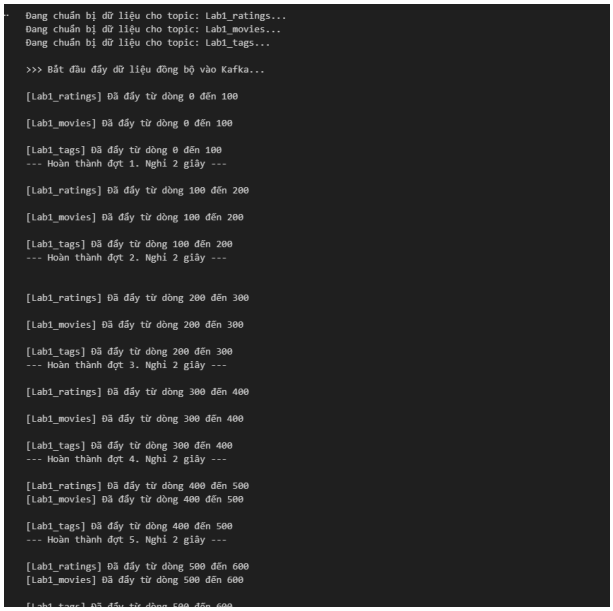

- Spark 2 - Consumers: lấy dữ liệu bằng cách readStream từ kafka để xử lí và hiển thị kết quả trên console. Đây là nơi sẽ thực hiện các nội dung của bài exercises

3 Exercises

3.1 Exercise 1

- Mục tiêu: Đọc dữ liệu từ Kafka và chuẩn hoá cấu trúc
- Input: Kafka topics: Lab1_ratings, Lab1_tags. Data của movies sẽ là data tĩnh lấy từ kaggle
- Cách làm: Định nghĩa Schema cho từng topics, chuyển đổi cột value từ JSON sang DataFrame và convert Unix timestamp sang định dạng Timestamp của Spark.

```python
from pyspark.sql.types import *

rating_schema = StructType([
    StructField("userId", IntegerType()),
    StructField("movieId", IntegerType()),
    StructField("rating", FloatType()),
    StructField("timestamp", LongType())
])

movie_schema = StructType([
    StructField("movieId", IntegerType()),
    StructField("title", StringType()),
    StructField("genres", StringType())
])

tag_schema = StructType([
    StructField("userId", IntegerType()),
    StructField("movieId", IntegerType()),
    StructField("tag", StringType()),
    StructField("timestamp", LongType())
])
```

[3] ✓ 0.0s Python

```python
from pyspark.sql.functions import *
brokers = "localhost:9092,localhost:9192,localhost:9292"
def read_kafka_topic(topic_name, schema):
    return spark.readStream \
        .format("kafka") \
        .option("kafka.bootstrap.servers", brokers) \
        .option("subscribe", topic_name) \
        .option("startingOffsets", "earliest") \
        .option("maxOffsetsPerTrigger", 100) \
        .load() \
        .selectExpr("CAST(value AS STRING)") \
        .select(from_json(col("value"), schema).alias("data")) \
        .select("data.*") \
        .withColumn("timestamp", to_timestamp(from_unixtime(col("timestamp"))))

ratings_stream = read_kafka_topic("Lab1_ratings", rating_schema)
tags_stream = read_kafka_topic("Lab1_tags", tag_schema)

movies_static = df_movies
```

3.2 Exercise 2

- Mục tiêu: Xác định thể loại phim đang được quan tâm nhất
- Input: data ratings streamming từ kafka và data movies static
- Cách làm: Kết hợp luồng ratings với dữ liệu movies. SỬ dụng explode để tách các thể loại phim (phân cách bởi dấu |) thành từng dòng riêng biệt sau đó đếm số lượng
- Output: Hiển thị bảng tổng sắp được cập nhật liên tục

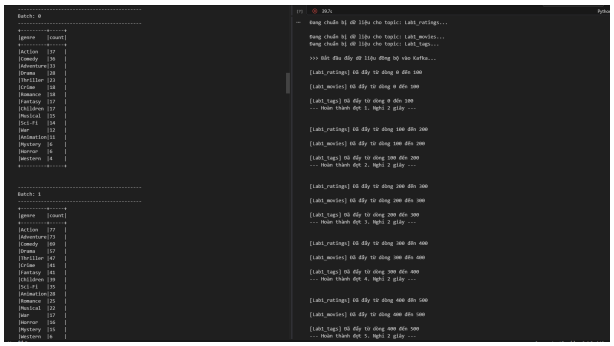

3.3 Excercise 3

- Mục tiêu: Tìm Top 3 phim có lượt rate cao nhất mỗi 5 phút
- Cách làm: Vì spark không hỗ trợ hàm xếp trực tiếp trên stream, ta dùng foreachBatch để biến mỗi micro-batch thành DataFrame tĩnh, sau đó dùng dense_rank để lấy top 3 của mỗi window
- Output: Hiển thị bảng dữ liệu top3 của mỗi window

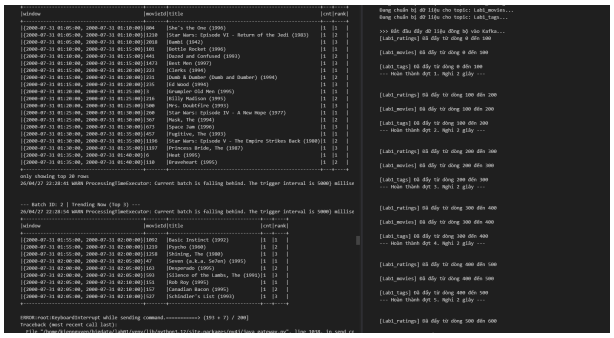

3.4 Exercise 4

- Mục tiêu: Kết hợp luồng Rating và Tag ngay khi phát sinh. Stream-Stream Join, Watermarks cả 2 phía.
- Cách làm: Thực hiện joun giữa hai stream ratings và tags
- Vấn đề: Vì yêu cầu cả hai stream đều phải có data trong cùng một thời điểm nên nhiều batch sẽ không có output gì cả ==> đúng thực tiễn

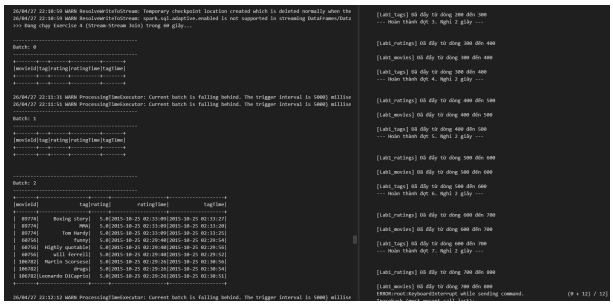

4 Mã nguồn

- Github repo: https://github.com/BunBoHue1/LAB_BigData/tree/main/LAB02
- Readme Lab02: https://github.com/BunBoHue1/LAB_BigData/blob/main/LAB02/README.md